

Guía de Ingesta Masiva, Organización por Años y Visor de GPCs

Esta guía detalla la gestión de documentos normativos en formato PDF, su organización por carpetas de año, el pipeline de ingesta automática, el catálogo de metadatos CIE-10 y la exportación de informes formativos en el sistema **Ateneo**.

1. Estructura de Directorios para Ingesta Masiva (../backend/data/raw_pdfs/)

Las ~60 Guías de Práctica Clínica emitidas por el Ministerio de Salud Pública (MSP) del Ecuador se organizan por año de publicación oficial dentro de subcarpetas dedicadas:

```
backend/data/raw_pdfs/
├── 2013/
│   ├── Guia-de-hemorragia-postparto.pdf
│   ├── Guia-de-gaucher.pdf
│   └── ...
├── 2014/
├── 2015/
├── 2016/
├── 2017/
├── 2018/
│   ├── guia_preencion_diagnostico_tratamiento_enfermedad_renal_cronica_2018.pdf
├── 2019/
│   ├── gpc_VIH_acuerdo_ministerial05-07-2019.pdf
│   ├── gpc_ehirn2019.pdf
│   └── gpc_hta192019.pdf
└── general/
    └── GP_Tuberculosis-1.pdf
```

2. Pipeline de Ingesta Recursiva y Vectorización Acelerada

2.1 Opciones de Ejecución de la Ingesta

Opción 1: Aceleración Élite en GPU NVIDIA A100 (Estándar MLOps Recomendado - < 60 segundos)

A través del notebook maestro `../backend/ingestion/colab_ingesta_benchmark_a100.ipynb`:

- Procesa los embeddings de 1024 tokens con precisión nativa **TF32/BF16** en Tensor Cores.
- Genera la base persistente **chroma_db/** con espacio métrico **cosine**.
- Empaqueta automáticamente el artefacto **chroma_db.zip** para descarga y despliegue inmediato en local o AWS.

Opción 2: Ejecución Local en CPU

Para procesar recursivamente todas las subcarpetas e indexar los fragmentos localmente:

```
py backend/ingestion/run_ingestion.py
```

2.2 Características Técnicas del Parser Avanzado

([../backend/ingestion/pdf_advanced_parser.py](#))

1. **Detección Automática de Año:** Extrae el año de la carpeta contenedora (2013, 2019, etc.) o del texto del acuerdo ministerial y lo almacena como metadato normativo `ano_publicacion`.
2. **Conversión de Tablas a Markdown (`pdfplumber`):** Convierte tablas de dosificación, criterios diagnósticos y matrices clínicas directamente a sintaxis Markdown:

```
| Parámetro Clínico | Criterio de Riesgo | Conducta MSP |
| --- | --- | --- |
| Presión Arterial | >= 160/110 mmHg | Sulfato de Magnesio IV |
```

3. **OCR Defensivo Multinivel ([../backend/ingestion/ocr_service.py](#)):** Si una página antigua carece de texto seleccionable pero contiene imágenes o flujogramas escaneados, el sistema renderiza la página a 180 DPI en memoria y ejecuta OCR automático (Local / Gemini Multimodal) preservando tablas y dosis sin pérdida de información.
4. **Manejo Defensivo de Fuentes Dañadas:** Omite streams de fuentes corruptas sin detener el procesamiento de los demás documentos.

3. Catálogo Normativo CIE-10 y Especialidades Médicas

([../backend/models/medical_catalog.py](#))

Ateneo integra un catálogo maestro ([../backend/data/catalogo_cie10_gpc.json](#)) que asocia a cada GPC sus metadatos nosológicos y clínicos:

- **Código y Descripción CIE-10:** Identificador de la Clasificación Internacional de Enfermedades (ej. **014.1** Preeclampsia Severa, **A90** Dengue, **I10** HTA, **N18** ERC).
- **Especialidad Médica Principal:** Clasificación por especialidad (*Ginecología y Obstetricia, Pediatría y Neonatología, Medicina Interna, Infectología, Neumología, Nefrología, Endocrinología, Genética y Enfermedades Raras, Cuidados Paliativos*).
- **Grupo Etario y Nivel de Atención:** Metadatos demográficos y de complejidad hospitalaria persistidos en cada fragmento en ChromaDB.

4. Endpoints y Visor PDF Interactivo

4.1 Endpoint de Localización de PDFs

- **Ruta:** `GET /api/cases/pdf-location/{guia_id}`
- **Función:** Busca recursivamente en las subcarpetas de `raw_pdfs/` el archivo correspondiente a `guia_id` y devuelve su URL estática accesible (`/static/pdfs/2019/gpc_hta192019.pdf`).

4.2 Componente Frontend ([../frontend/src/components/PdfViewerModal.jsx](#))

- Al recibir una evaluación formativa, la tarjeta de feedback ([../frontend/src/components/FeedbackCard.jsx](#)) incluye el botón "**Ver en Guía Oficial (Pág. X)**".
 - Al hacer clic, abre un visor PDF integrado que salta directamente a la página exacta de la normativa (`#page={pagina}`), permitiendo auditar la fuente oficial en tiempo real.
-

5. Exportador de Dictamen Clínico en PDF Institucional

5.1 Servicio Generador ([../backend/services/pdf_report_generator.py](#))

- Genera documentos PDF membretados de alta resolución mediante **ReportLab**.
- Incluye:
 - Membrete institucional oficial del proyecto Ateneo y MSP Ecuador.
 - Desglose cualitativo y cuantitativo del puntaje ($\$/10\text{pts}\$$).
 - Tablas en dos columnas de Aciertos Clínicos vs Omisiones / Puntos a Mejorar.
 - Cuadro sombreado con la Cita Normativa Oficial y número de página exacto.
 - Hash de integridad criptográfica SHA-256 (**ATENEO-MSP-XXXXXXXX**) para auditoría académica.

5.2 Endpoint de Streaming

- **Ruta:** **POST** `/api/evaluate/export-pdf`
- **Content-Type:** `application/pdf` (Descarga directa en streaming para navegadores).