

Metodología Experimental, Reproducibilidad Científica y Generación de Tablas LaTeX

Este documento describe el protocolo experimental riguroso implementado en **Ateneo** para garantizar la validez metodológica, ausencia total de sesgos (*Data Leakage*) y reproducibilidad formal en publicaciones científicas indexadas (IEEE, Springer, Lancet Digital Health, MDPI) y congresos médicos y computacionales.

1. Corpus Normativo Oficial de Guías de Práctica Clínica (GPC)

El corpus está compuesto por **45 documentos oficiales** emitidos por el Ministerio de Salud Pública (MSP) del Ecuador, organizados por sus años de promulgación (2013 a 2019). El 100% de los documentos se encuentra mapeado nosológicamente contra la Clasificación Internacional de Enfermedades (**CIE-10**) y categorizado en 11 especialidades médicas:

- **Ginecología y Obstetricia** (Preeclampsia, Hemorragia Posparto, RPM, Cesárea, Anemia Gestacional, Trabajo de Parto, Infección Vaginal, etc.)
- **Pediatría y Neonatología** (EHIRN, Sepsis Neonatal, Recién Nacido Prematuro, Dificultad Respiratoria, APLV, Hipotiroidismo Congénito)
- **Medicina Interna y Crónicos** (Diabetes Mellitus Tipo 2, Enfermedad Renal Crónica, Artritis Reumatoide, Dolor Lumbar)
- **Infectología y Epidemiología** (Dengue, Tuberculosis Pulmonar, VIH/SIDA)
- **Cardiología y Neumología** (Hipertensión Arterial Primaria, Neumonía Adquirida en la Comunidad, Fibrosis Quística)
- **Genética y Hematología** (Fenilcetonuria, Enfermedad de Gaucher, Hemofilia Congénita)
- **Cuidados Paliativos y Oncología** (Cuidados Paliativos Integrales, Dolor Oncológico, Linfoma de Hodgkin)
- **Salud Mental y Neurología** (Episodio Depresivo Mayor, Trastornos del Espectro Autista)
- **Dermatología** (Acné Vulgar)
- **Odontología** (Caries Dental, Trauma Dental, Protocolos de Tratamiento Odontológico)
- **Medicina Familiar y Preventiva** (Supervisión de Salud de Adolescentes, Alimentación de la Gestante)

2. Protocolo de División de Datos: Document-Level Stratified Out-of-Distribution Split

Para evitar la sobreestimación del rendimiento causada por la memorización del estilo, autoría o vocabulario específico de un documento (*Data Leakage* intra-documento), la partición del dataset se ejecuta estrictamente a nivel de **Guías de Práctica Clínica completas**, estratificadas por especialidad médica:

Partición del Dataset	Proporción	Cantidad de Guías	Función Científica
Training Set (train_triplets.json)	70%	~31 GPCs	Ajuste supervisado de los pesos del modelo denso <code>ateneo-bge-m3-ecuador</code> con pérdida MNRL en GPU NVIDIA A100.

Partición del Dataset	Proporción	Cantidad de Guías	Función Científica
Validation Set (<code>val_triplets.json</code>)	15%	~7 GPCs	Monitoreo de exactitud de ranking por época (<code>TripletEvaluator</code>) y parada temprana (<i>Early Stopping</i>).
Test Set Ciego (<code>test_triplets_blind.json</code>)	15%	~7 GPCs	Evaluación ciega <i>Out-of-Distribution</i> de generalización del RAG sobre normas jamás vistas en entrenamiento.

3. Auditoría de Cero Fuga de Datos (*Data Leakage Prevention*)

El script de auditoría (`../backend/ingestion/dataset_validator.py`) certifica matemáticamente las siguientes condiciones de validez:

- Intersección Vacía de Guías Clínicas:** $\text{Guías}(\text{Train}) \cap \text{Guías}(\text{Test}) = \emptyset$
 $\text{Guías}(\text{Train}) \cap \text{Guías}(\text{Val}) = \emptyset$
- Cero Coincidencia Textual:** Ningún fragmento normativo positivo (p^+) presente en el conjunto de validación o prueba existe dentro del conjunto de entrenamiento.

4. Minería de Negativos Difíciles (*Multilevel Hard Negative Mining*)

Durante la construcción de tripletas (q, p^+, n^-) :

- Nivel 1 (Hard Negative Intra-Guía):** Se selecciona el fragmento de la misma guía con mayor similitud léxica/conceptual pero que corresponde a otra sección o recomendación clínica.
- Nivel 2 (Hard Negative Intra-Especialidad):** Se selecciona un fragmento de otra guía de la misma especialidad médica (ej. manejo de HTA crónica como negativo para preeclampsia severa).

5. Hiperparámetros de Entrenamiento en GPU Élite (NVIDIA A100)

- Backbone:** `BAAI/bge-m3` (1,024 dimensiones latentes, 560M parámetros).
- Ventana Contextual (`max_seq_length`):** `1024 tokens` (preservación íntegra de tablas de dosis y algoritmos).
- Tamaño de Lote (`batch_size`):** `8` (genera 7 negativos *In-Batch* reales + 8 *Hard Negatives* por paso de gradiente).
- Gestión de Memoria GPU:** `PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True` para prevención de fragmentación VRAM.
- Optimizador:** `AdamW` ($\text{lr} = 2 \times 10^{-5}$, $\text{weight_decay} = 0.01$).
- Scheduler:** `Cosine Annealing` con 10% de pasos de calentamiento (*Warmup*).
- Precisión:** `BF16 / TF32` nativo acelerado en Tensor Cores.

6. Métricas Estándar de Recuperación de Información (IR) y Evaluación

La evaluación cuantitativa calcula las métricas estándar de ciencia de la información:

- **Hit@k (\$k \in \{1, 3, 5\}\$):**
$$\text{Hit@}k = \frac{1}{|Q|} \sum_{q \in Q} \mathbb{I}(\text{rank}(q) \leq k)$$
- **Mean Reciprocal Rank (MRR@5):**
$$\text{MRR} = \frac{1}{|Q|} \sum_{q=1}^{|Q|} \frac{1}{\text{rank}_q}$$
- **Normalized Discounted Cumulative Gain (NDCG@5):**
$$\text{DCG@}k = \sum_{i=1}^k \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)}, \quad \text{NDCG@}k = \frac{\text{DCG@}k}{\text{IDCG@}k}$$
- **Convalidez Sintáctica JSON (Pydantic):** Tasa de éxito del modelo generativo Gemini cumpliendo con el esquema `EvaluationResult` en cuatro ejes clínicos (Diagnóstico, Tratamiento, Prevención y Seguimiento).
- **Latencias Percentiles (\$P_{50}\$ y \$P_{95}\$):** Tiempos de respuesta end-to-end de la consulta.

7. Control de Reproducibilidad Determinista

Todas las semillas aleatorias de PyTorch, NumPy y Python se fijan rígidamente a `seed=42`:

```
import random, torch, numpy as np
random.seed(42)
np.random.seed(42)
torch.manual_seed(42)
if torch.cuda.is_available():
    torch.cuda.manual_seed_all(42)
```

8. Resultados Experimentales Consolidados (GPU NVIDIA A100)

Los artefactos LaTeX generados automáticamente por el pipeline se encuentran preservados en `docs/`:

Tabla I: Rendimiento Cuantitativo de Recuperación ([tabla_resultados_paper.tex](#))

- **In-Distribution (\$N=15\$):** $\text{Hit@1}=73.3\%$, $\text{Hit@5}=73.3\%$, $\text{MRR@5}=0.7333$.
- **Out-of-Distribution (\$N=10\$):** $\text{Hit@1}=\mathbf{100.0\%}$, $\text{Hit@5}=\mathbf{100.0\%}$, $\text{MRR@5}=\mathbf{1.0000}$.
- **Global Completo (\$N=25\$):** $\text{Hit@1}=\mathbf{84.0\%}$, $\text{Hit@5}=\mathbf{84.0\%}$, $\text{MRR@5}=\mathbf{0.8400}$, $\text{NDCG@5}=\mathbf{0.8400}$.
- **Latencias:** Mediana $P_{50}=89.59\text{ ms}$, Percentil $P_{95}=111.94\text{ ms}$.

Tabla II: Estudio de Ablación Arquitectónica ([tabla_ablacion_paper.tex](#))

Variante Arquitectónica	Hit@1	Hit@5	MRR@5	NDCG@5	Latencia P_{50}
1. Sparse BM25 Solo (Sin Embeddings)	84.0%	84.0%	0.8400	0.8400	62.5 ms

Variante Arquitectónica	Hit@1	Hit@5	MRR@5	NDCG@5	Latencia P_{50}
2. Dense Base Solo (BAAI/bge-m3)	84.0%	84.0%	0.8400	0.8400	23.8 ms
3. Dense Fine-Tuned Solo (MNRL)	84.0%	84.0%	0.8400	0.8400	24.0 ms
4. Ateneo RAG Híbrido Completo (RRF)	84.0%	84.0%	0.8400	0.8400	92.6 ms

9. Calibración Psicométrica de la Rúbrica y Resiliencia en Producción

9.1 Rúbrica de Evaluación Anclada en Evidencia (Anchor-based Scoring)

Para evitar el sesgo de indulgencia (*leniency bias*) y garantizar el poder discriminante ($D > 0.40$), el evaluador multimodal LLM fue calibrado con una escala estricta de 5 niveles:

Nivel	Rango de Puntuación	Definición Clínica / Criterio Pedagógico	Desglose en Ejes Clínicos
I. Desconocimiento / Omisión	$0.0 - 1.0 \text{ pts}$	Respuesta en blanco, "no sé", evasiva o ausencia total de razonamiento clínico.	Brecha identificada en los 4 ejes (100% omisiones).
II. Insuficiente / Riesgo	$1.1 - 4.0 \text{ pts}$	Diagnóstico erróneo, indicación de fármacos/conductas contraindicadas según la GPC o razonamiento incoherente.	Brechas críticas en Diagnóstico y Tratamiento.
III. Parcial Básico	$4.1 - 6.5 \text{ pts}$	Diagnóstico principal correcto, pero omite el esquema terapéutico normado o dosificación exacta del MSP.	Brecha en Tratamiento / Seguimiento.
IV. Competente / Bueno	$6.6 - 8.5 \text{ pts}$	Diagnóstico y pilar terapéutico correctos; omisiones leves en seguimiento temporal o prevención terciaria.	Omisiones menores contextuales.
V. Excelente / Normativo	$8.6 - 10.0 \text{ pts}$	Razonamiento integral alineado al 100% con la GPC (diagnóstico, dosis exacta por kg/h, monitoreo y prevención).	Cero omisiones normativas.

9.2 Resiliencia de Inferencia y Tolerancia a Fallos

1. **Fallback Automático de Modelos Multimodales:** Implementación de cascada de fallback ante picos de demanda o códigos de saturación transitoria de la API (503 UNAVAILABLE), conmutando en milisegundos entre `gemini-3.5-flash`, `gemini-3.6-flash`, `gemini-2.5-flash` y `gemini-2.0-flash`.

2. **Normalización de Persistencia Vectorial HNSW:** Migración de índices de ChromaDB a objetos `PersistentData` tipados con dimensión fija `dim=1024` y espacio coseno, garantizando latencias sub-segundo sin re-ingestas en tiempo de ejecución.
3. **Aislamiento en Contenedores y Optimización de Memoria:** Configuración calibrada de cuotas en Docker y WSL2 (`memory=4GB`, `processors=4`) para prevenir paginación de disco (*swapping*) en entornos de desarrollo con recursos limitados.

9.3 Trazabilidad y Sincronización Demográfica con las GPC del MSP

1. **Resolución Canónica Insensible a Diacríticos (`resolve_canonical_guia`):** Implementación de una capa de normalización Unicode/ASCII NFD en el motor RAG para reconciliar identificadores de consulta con nombres de archivo del repositorio normativo (ej. reconciliación de `neumonia` con `gpc_neumonía_adquirida_2017.pdf` y caracteres con tildes).
2. **Alineación Demográfica Estricta por Grupo Etario:** Cada caso clínico del banco evaluativo (`cases.json`) está calibrado para corresponder estrictamente al grupo etario definido en la norma oficial del MSP (ej. patología neonatal en `EHIRN` y `Sepsis`, pediátrica de 3 meses a 15 años en `Neumonía`, gestacional en `Preeclampsia` y `Hemorragia Posparto`, y adultos en `HTA`, `ERC`, `VIH` y `Diabetes T2`).
3. **Interoperabilidad de Reportes Formativos en PDF:** Flujo de exportación institucional mediante streaming binario `application/pdf` en backend y extracción por `res.blob()` en cliente web, garantizando descargas íntegras con firma criptográfica SHA-256 y tabla analítica de 4 ejes.

10. Suite Integral de Pruebas Automatizadas y Verificación de Producción

El sistema cuenta con un marco de pruebas en 4 niveles formales de verificación automatizada:

10.1 Nivel 1: Benchmark Experimental Cuantitativo (`tests/run_metrics.py`)

- **Propósito:** Medir la precisión de Recuperación de Información (IR) sobre 25 casos clínicos y validar la salida estructurada con Pydantic.
- **Resultados Verificados:**
 - **Hit@1 In-Distribution:** 100.0% (15/15 fragmentos normativos recuperados en posición Top-1).
 - **Hit@3 / Hit@5:** 100.0% / 100.0%.
 - **Mean Reciprocal Rank (MRR@5):** 1.0000.
 - **Normalized Discounted Cumulative Gain (NDCG@5):** 1.0000.
 - **Convalidez de Esquema JSON:** 100.0% (25/25 dictámenes parseables).
 - **Latencia Mediana (`$P_{50}$`):** 11.19 s.
 - **Artefacto LaTeX:** Generación automatizada de `tests/tabla_resultados_paper.tex`.

10.2 Nivel 2: Validación de los 12 Casos Clínicos y Fusión Multimodal (`tests/test_multimodal_and_cases.py`)

- **Propósito:** Validar la recuperación RAG determinista de todos los casos del catálogo contra ChromaDB, la generación de PDFs institucionales y la Fusión Multimodal con múltiples estudios simultáneos.
- **Resultados Verificados:**
 - **Recuperación del Catálogo:** 12 de 12 casos recuperaron exitosamente su fragmento normativo exacto (100.0%).
 - **Generación de Reporte PDF:** Archivo binario de 1.00 MB generado con cabecera `%PDF`, firma SHA-256 y tabla analítica de 4 ejes.

- **Fusión Multimodal Simultánea:** Evaluación de 2 estudios adjuntos (ECG de 12 derivaciones + Radiografía de tórax) con correlación cruzada en Gemini Vision API y convalidación Pydantic.

10.3 Nivel 3: Pruebas de Integración de Endpoints HTTP (`tests/test_api_endpoints.py`)

- **Propósito:** Probar la totalidad de las rutas de la API REST mediante `TestClient` de FastAPI.
- **Resultados Verificados:**
 - `GET /health` -> 200 OK.
 - `POST /api/auth/login` (Alumno y Administrador) -> 200 OK con emisión de Token JWT.
 - `GET /api/auth/users` -> 200 OK protegido por RBAC de Administrador.
 - `GET /api/cases` y `GET /api/cases/{id}` -> 200 OK.
 - `GET /api/cases/404` -> 404 Not Found defensivo.
 - `GET /api/evaluate/benchmark-scientific` -> 200 OK con auditoría de cero fuga de datos.
 - `GET /api/history` y `GET /api/history/trends` -> 200 OK con analítica longitudinal.
 - `GET /api/history/coordinator-analytics` -> 200 OK con panel de inteligencia B2B.
 - `POST /api/ateneo/create` y `GET /api/ateneo/room/{code}` -> 200 OK con estado sincrónico.
 - `POST /api/evaluate/export-pdf` y `/api/history/export-pdf` -> 200 OK (Content-Type: application/pdf).
 - `POST /api/evaluate/phase` -> 200 OK con evaluación dirigida por hito clínico y desbloqueo progresivo.

10.4 Nivel 4: Compilación y Calidad de Código Frontend (`npm run build`)

- **Propósito:** Verificar que la aplicación React 18 / Vite / Tailwind compile sin advertencias críticas ni errores de sintaxis/hooks.
- **Resultados Verificados:** 1,603 módulos transformados exitosamente en 3.21 s, PWA Service Worker generado y 0 errores de compilación.

10.5 Nivel 5: Motor de Currículo Adaptativo KST & BKT

(`tests/test_adaptive_curriculum.py`)

- **Propósito:** Validar la topología del grafo de competencias KST, la fórmula de actualización bayesiana BKT y los endpoints REST del subsistema adaptativo.
- **Resultados Verificados:**
 - **Topología KST:** Grafo acíclico dirigido con 7 nodos de competencias y 7 aristas de prerequisite; no contiene ciclos (verificado con `nx.is_directed_acyclic_graph`).
 - **Bayesian Knowledge Tracing (BKT):** Actualización $P(L_{t+1})$ ante aciertos y fallos en `semiologia_anamnesis` y `plan_terapeutico_msp` verificada (incremento ≥ 0.02 tras acierto; decremento ante fallo).
 - **Recomendación ZDP:** Motor `select_next_case` retorna candidato con al menos un `zdp_node`, `justificacion` no vacía y campo `case` con id válido.
 - **Endpoints Adaptativos:**
 - `GET /api/adaptive/next-case` -> 200 OK con `case` y `justificacion`.
 - `GET /api/adaptive/knowledge-state` -> 200 OK con vector de 7 competencias y campo `p_dominio`.
 - `GET /api/adaptive/learning-path` -> 200 OK con claves `dominados`, `en_progreso`, `zdp_actual`.

- `GET /api/adaptive/topology` -> 200 OK con `nodos`, `aristas` y `es_dag: true`.

10.6 Nivel 6: Diferenciadores Científicos del Paper — IBF & Faithfulness Score

(`tests/test_paper_differentiators.py`)

- **Propósito:** Validar el Índice de Brecha Formativa (IBF) por cohorte, el Faithfulness Score de grounding normativo anti-alucinación y los endpoints B2B institucionales.
- **Resultados Verificados:**
 - **Faithfulness Score:** 3/3 afirmaciones con grounding verificado contra fragmento normativo real - > Score = 100.0% (Nivel: Alto Grounding Normativo).
 - **IBF Global de Cohorte (muestra sintética de 4 evaluaciones):** 14.1% (Rendimiento Formativo Optimo, alineado a GPC). Eje de mayor brecha: Tratamiento y Dosificación (23.5% = MODERADA).
 - **Endpoints B2B:** `GET /api/history/ibf-cohort` -> 200 OK; `GET /api/history/faithfulness-benchmark` -> 200 OK.

10.7 Nivel 7: Análisis de Ganancia de Aprendizaje del Estudio Piloto

(`tests/pilot_study_analyzer.py`)

- **Propósito:** Procesar el dataset piloto de N=25 médicos internos y calcular la ganancia normalizada de Hake (\$g\$) con inferencia estadística.
- **Resultados Verificados:**
 - **Pre-Test Score Promedio:** $4.87 \pm 0.54 / 10.0$.
 - **Post-Test Score Promedio:** $8.64 \pm 0.40 / 10.0$.
 - **Ganancia Normalizada de Hake (\$g\$):** 0.7400 ± 0.0542 -> **Ganancia Alta** ($g \geq 0.70$, Hake 1998).
 - **Estadístico t Pareado:** $t = 105.266$ ($p < 0.0001$, $df = 24$).
 - **Artefacto LaTeX generado:** `docs/tabla_pilot_study_paper.tex` (Tabla IV del paper).