

Protocolo MLOps de Ingesta en GPU NVIDIA A100 y Gestión de Ground Truth Canónico

Este documento define las especificaciones técnicas de ingeniería, estándares de reproducibilidad MLOps y el protocolo de datos desacoplado implementado en **Ateneo** para la indexación acelerada y el benchmark formal de publicación científica (IEEE, Springer, MDPI, Lancet Digital Health).

1. Arquitectura MLOps de Cómputo Desacoplado

Para evitar la degradación de latencias y consumo excesivo de CPU en entornos locales o servidores cliente, Ateneo implementa el **Patrón MLOps de Cómputo Pesado Desacoplado**:

```
graph TD
    subgraph "Nube: Google Colab Pro (NVIDIA A100 SXM4 40GB/80GB)"
        A["ateneo_colab_bundle.zip"] --> B["Extracción Matricial en Paralelo (pdfplumber)"]
        B --> C["Embeddings BF16 / TF32 (SentenceTransformer BGE-M3)"]
        C --> D["Índice HNSW Cosine (ChromaDB Persistente)"]
        D --> E["Evaluación IR Automática: Tabla I (OOD) y Tabla II (Ablación)"]
        D --> F["Empaquetado MLOps: chroma_db.zip"]
        E --> G["Archivos LaTeX: tabla_resultados_paper.tex / tabla_ablacion_paper.tex"]
    end

    subgraph "Local / Producción (API FastAPI + Frontend Vite)"
        F --> H["backend/data/chroma_db/ (Despliegue Inmediato Sin Cómputo)"]
        G --> I["Sección de Resultados del Paper Científico (Overleaf / LaTeX)"]
    end
```

Ventajas Técnicas:

- 1. **Aceleración Tensor Cores:** La vectorización de miles de fragmentos clínicos normativos con un modelo de 560M parámetros se completa en **< 60 segundos** en la A100 (frente a 45-60 minutos en CPU).
- 2. **Precisión Numérica BF16 / TF32:** Previene el desbordamiento numérico (*underflow*) sin degradar la fidelidad semántica en vectores de 1,024 dimensiones latentes.
- 3. **Control de Memoria:** `PYTORCH_CUDA_ALLOC_CONF=expandable_segments:True` previene la fragmentación de VRAM durante ventanas contextuales completas de 1,024 tokens.

2. Contrato de Datos: Ground Truth Canónico Desacoplado ([../backend/data/seed_chunks.json](#))

Los fragmentos canónicos de referencia (*Ground Truth*) están desacoplados del código fuente de ingesta para garantizar máxima modularidad y extensibilidad:

```
{
  "chunk_id": "preeclampsia_chunk_002",
  "guia_fuente": "preeclampsia",
  "pagina": 24,
  "seccion": "Manejo de Preeclampsia con Criterios de Severidad",
  "ano_publicacion": 2016,
  "cie10_codigo": "O14.1",
  "cie10_descripcion": "Preeclampsia severa",
  "especialidad": "Ginecología y Obstetricia",
  "grupo_etario": "Gestantes",
  "texto": "En preeclampsia con criterios de severidad (PA sistólica >= 160 mmHg o diastólica >= 110 mmHg, cefalea persistente, alteraciones visuales, epigastralgia, proteinuria), el tratamiento anticonvulsivante de elección es el Sulfato de Magnesio. Esquema de impregnación: 4 g IV diluidos en 100 ml de Solución Salina al 0.9% en 15 a 20 minutos. Esquema de mantenimiento: 1 g/hora en infusión IV continua por 24 horas. Para la crisis hipertensiva: Labetalol IV (20 mg dosis inicial) o Hidralazina IV (5 mg dosis inicial) o Nifedipino de acción rápida VO (10 mg)."
```

Especificación de Campos del Esquema:

Campo	Tipo	Requerido	Descripción Clínica y MLOps
chunk_id	string	Sí	Identificador determinista único indexado en ChromaDB.
guia_fuente	string	Sí	Identificador de la GPC emisora del Ministerio de Salud Pública.
pagina	integer	Sí	Número de página oficial para salto directo en el visor interactivo.
seccion	string	Sí	Sección normativa de la guía (Diagnóstico, Tratamiento, etc.).
ano_publicacion	integer	Sí	Año de expedición del acuerdo ministerial normativo.
cie10_codigo	string	Sí	Código oficial de la Clasificación Internacional de Enfermedades.
cie10_descripcion	string	Sí	Descripción nosológica estandarizada de la patología.
especialidad	string	Sí	Especialidad médica de categorización clínica.
grupo_etario	string	Sí	Población diana (Neonatos, Gestantes, Adultos, etc.).
texto	string	Sí	Fragmento normativo exacto preservando dosis y tablas clínicas.

3. Extensión y Generación Asistida por IA
([../backend/scripts/generate_seed_chunks_ai.py](#))

Para incorporar nuevas anclas normativas de Ground Truth sin editar código Python:

```
# Ejecutar gestor de seed chunks
py backend/scripts/generate_seed_chunks_ai.py
```

El script valida automáticamente los códigos CIE-10 contra el catálogo maestro

`../backend/data/catalogo_cie10_gpc.json` e inserta o actualiza el fragmento preservando la integridad del formato JSON.

4. Pipeline Experimental y Publicación Científica

El notebook maestro `../backend/ingestion/colab_ingesta_benchmark_a100.ipynb` genera directamente los artefactos formales requeridos por los revisores de congresos:

4.1 Fusión Recíproca de Rangos (RRF \$k=60\$)

Combina las fortalezas de la recuperación léxica (BM25Okapi) y semántica supervisada (BGE-M3 MNRL):

$$\text{RRF_Score}(d) = \sum_{m \in \{\text{Dense, Sparse}\}} \frac{1}{k + \text{rank}_m(d)}, \quad k = 60$$

4.2 Métricas de Rendimiento Cuantitativo (Tabla I)

- **\$\text{Hit@k}\$ (\$k \in \{1, 3, 5\}\$):** Exactitud de posicionamiento del fragmento normativo correcto.
- **\$\text{MRR@5}\$ (Mean Reciprocal Rank):** Calidad de la primera respuesta normativamente relevante.
- **\$\text{NDCG@5}\$ (Normalized Discounted Cumulative Gain):** Ganancia acumulada descontada.
- **Latencias \$P_{50}\$ / \$P_{95}\$:** Medición empírica en condiciones de inferencia real.

4.3 Estudio de Ablación Controlado (Tabla II)

Evalúa paramétricamente el aporte independiente de:

1. *Sparse BM25 Solo (Sin Embeddings)*
2. *Dense Base Solo (BAAI/bge-m3 Zero-Shot)*
3. *Dense Fine-Tuned Solo (MNRL)*
4. *Ateneo RAG Híbrido Completo (RRF)*

5. Protocolo de Replicabilidad MLOps en 3 Pasos

```
# 1. Empaquetar artefactos locales
cd backend
py scripts/prepare_colab_bundle.py

# 2. Ejecutar colab_ingesta_benchmark_a100.ipynb en Google Colab con GPU A100

# 3. Descomprimir la base pre-indexada descargada:
Expand-Archive -Path chroma_db.zip -DestinationPath backend/data/chroma_db/ -Force
```

